

# Statistiques bayésiennes

Othmane Ettaqi et Henry Watiotienne  
Encadré par Mme Ophélie Guin

Département de Mathématiques  
Université Lille

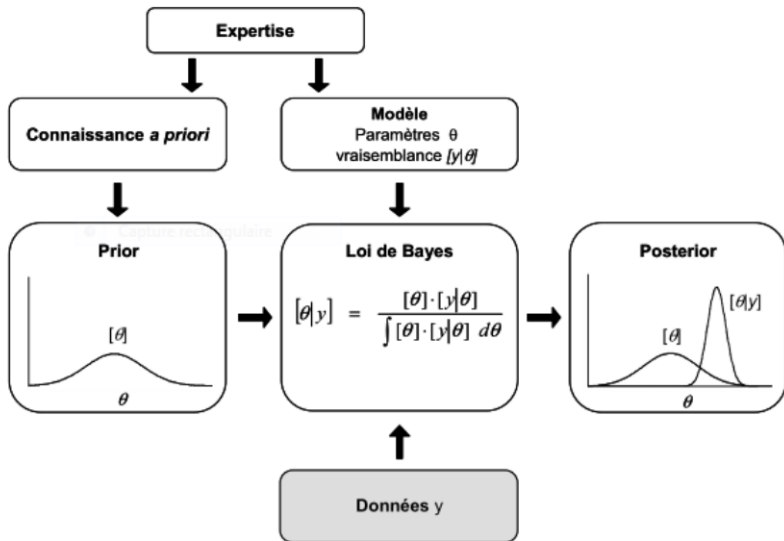
30 mai 2023



# Plan de la Présentation

- 1 Principe général
- 2 Modèle gaussien à moyenne et variance inconnus
  - Illustration avec un jeu de données
- 3 Modèle de régression linéaire simple
  - lois a posteriori
  - Illustration avec un jeu de données
- 4 Modèle de régression semi-paramétrique
  - Algorithme de Gibbs
  - Sortie Graphique
  - Application aux données climatiques

# Principe général



# Modèle gaussien à moyenne et variance inconnus

On considère le modèle bayésien sera le suivant :

$$x_i | \mu, \tau \sim \mathcal{N}(\mu, \tau) \text{ iid. } i = 1, \dots, n$$

$$\mu | \tau \sim \mathcal{N}(\mu_0, n_0 \tau)$$

$$\tau \sim \mathcal{G}(\alpha, \beta)$$

On trouve par le calcul les lois a posteriori suivantes :

$$\mu | x_1, \dots, x_n, \tau \sim \mathcal{N} \left( \frac{n}{n+n_0} \bar{x} + \frac{n_0}{n+n_0} \mu_0, \frac{1}{(n+n_0)\tau} \right)$$


$$\tau | x_1, \dots, x_n \sim \mathcal{G} \left( \alpha + \frac{n}{2}, \frac{\sum (x_i - \bar{x})^2}{2} + \frac{nn_0}{n+n_0} (\mu_0 - \bar{x})^2 \right)$$

# Illustration avec un jeu de données


Ici  $\tau = \frac{1}{\sigma^2}$  et on simule les  $x_i \sim \mathcal{N}(9, 1.5^2)$  On choisit les a priori

suivantes :  $\mu|x, \sigma^2 \sim \mathcal{N}\left(8, \frac{\sigma^2}{0.5}\right)$  et  $\sigma^2 \sim \text{IG}(1, 1)$


Distribution de la loi a posteriori de sigma^2 n= 10




Distribution de la loi a posteriori de mu n= 10




Distribution de la loi a posteriori de sigma^2 n= 100




Distribution de la loi a posteriori de mu n= 100



Distribution de la loi a posteriori de sigma^2 n= 1000



Distribution de la loi a posteriori de mu n= 1000



# Modèle de régression linéaire simple

On considère maintenant le modèle de régression suivant :  $Y = X\beta + \epsilon$

$$\text{avec } Y = \begin{pmatrix} y_1 \\ \dots \\ y_n \end{pmatrix}; X = \begin{pmatrix} 1 & x_1 \\ \dots & \dots \\ 1 & x_n \end{pmatrix}; \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}; \epsilon = \begin{pmatrix} \epsilon_1 \\ \dots \\ \epsilon_n \end{pmatrix} \text{ et } \epsilon_i \sim \mathcal{N}(0, \sigma^2)$$

Vraisemblance :

$$\mathcal{L}(Y|X, \beta, \sigma^2) \propto (\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2}(Y - X\beta)^T(Y - X\beta)\right)$$

Lois a priori :

$$\pi(\sigma^2) \sim IG\left(\frac{v_0}{2}, \frac{v_0 s_0}{2}\right)$$

$$\pi(\beta|\sigma^2) \sim \mathcal{N}(\mu_0, \sigma^2 \Lambda_0^{-1})$$

Connaissant la vraisemblance et nos lois a priori on peut calculer les lois a posteriori :

$$\beta | \sigma^2, Y, X \sim \mathcal{N}(\mu_n, \sigma^2 \Lambda_n^{-1})$$


$$\Lambda_n = (X^T X + \Lambda_0)$$

$$\mu_n = (\Lambda_n)^{-1} (X^T X \hat{\beta} + \Lambda_0 \mu_0) \quad \hat{\beta} \text{ l'estimateur des moindres carrés .}$$


$$\sigma^2 | Y, X \sim IG(a_n, b_n) \quad a_n = \frac{\nu_0 + n}{2} \quad b_n = \frac{\nu_0 s_0^2 (Y^T Y + \mu_0^T \Lambda_0 \mu_0 - \mu_n^T \Lambda_n \mu_n)}{2}$$

# Illustration avec un jeu de données


Prior, likelihood and posterior for  $\beta$




Prior, likelihood and posterior for  $\alpha_{\bar{x}}$



Predictions with 95% bounds



Régression linéaire simple



Régression linéaire :  $\hat{\alpha} = 239.147$   $\hat{\beta} = -19.683$   $E(\alpha|x, y) = 181.3$  et  $E(\beta|x, y) = -17.29$ .



# Modèle de régression semi-paramétrique

$$y_i = f(x_i) + \epsilon_i \quad \epsilon_i \sim \mathcal{N}(0, \sigma^2)$$


Avec une approche classique, on peut obtenir  $f$  comme le minimiseur de la somme des carrés pénalisée suivante :

$$J(f) = \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \int \left( f''(x) \right)^2 dx$$


$\lambda$  est un paramètre de lissage utilisé pour contrôler l'allure de la courbe et ainsi obtenir des courbes plus ou moins lisses.

# Influence de $\lambda$


Paramètre lambda = 0.1




Paramètre lambda = 0.4



Paramètre lambda = 0.6



Paramètre lambda = 1



# Approche bayésienne

$$f = (f(x_1), \dots, f(x_n)) \quad y = (y_1, \dots, y_n)$$

$$y|f, \sigma^2 \sim \mathcal{N}_m(f, \sigma^2 I)$$

Loi a priori :  $f \sim \mathcal{N}_m(0; K^- \tau^2)$   $K^-$  est l'inverse généralisé de  $K$  et  
 $K^- = B\Omega^- B^T$

$$\pi(\sigma^2) \sim IG(a, b)$$

Lois a posteriori :  $f|y, \sigma^2 \sim \mathcal{N}_m(Sy, \sigma^2 S)$  Avec  $S = B(B^T B + \lambda \Omega)^{-1} B^T$

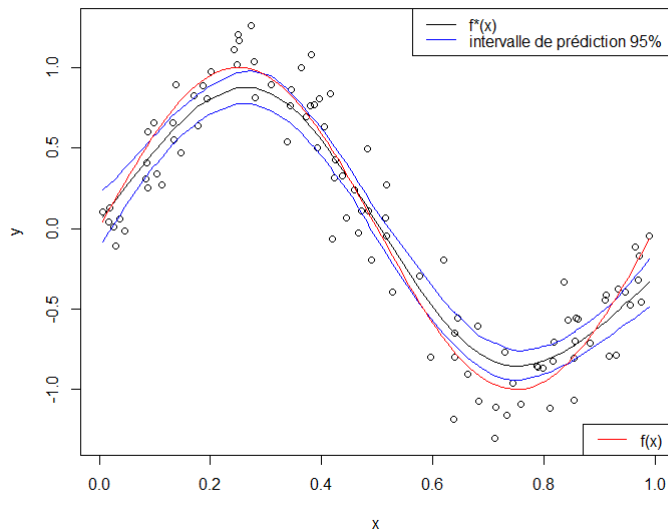
$$\sigma^2|f, y \sim IG\left(\frac{n}{2} + a, \frac{1}{2}(y - f)^T(y - f) + b\right)$$

# Algorithme de Gibbs

Avant d'appliquer notre algorithme on génère des données  $X \sim \mathcal{U}(0, 1)$   
Puis on applique aux points  $X$  la fonction  $f(x) = \sin(2\pi x)$  et on ajoute une perturbation  $\epsilon \sim \mathcal{N}(0, 0.04)$

- On initialise  $f_0$  et  $\sigma_0^2$
- Pour  $i = 1, \dots, N$ 
  - On Calcule la matrice  $S(\lambda)$
  - On simule  $f_i | \sigma_{i-1}^2, y \sim \mathcal{N}_m \left( S(\lambda)y, \sigma^2 S(\lambda) \right)$
  - On simule  $\sigma_i^2 | f_i, y \sim \text{IG} \left( \frac{n}{2} + a, \frac{1}{2} (y - f)^T (y - f) + b \right)$
  - On calcule  $\lambda = \sigma_i^2 / \tau_i^2$

# Sortie Graphique



# Application aux données climatiques




Figure 9: Régression bayésienne semi-paramétrique pour les températures maximales en fonction des années à Lyon.




Figure 10: Régression bayésienne semi-paramétrique pour les températures maximales en fonction des années à Brindisi.




Figure 12: Régression bayésienne semi-paramétrique pour les températures maximales en fonction des années à Helsinki.




Figure 13: Régression bayésienne semi-paramétrique pour les températures maximales en fonction des années à Cape Sterlegov.